Librerías

In [1]:
```python
import os

import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import plotly.graph_objects as go

import sklearn
from sklearn.preprocessing import MinMaxScaler

import plotly.express as px
from plotly.subplots import make_subplots
```

Llamado Dataset

In [2]:
```python
# Obtener el directorio actual de trabajo
directorio_actual = os.getcwd()

# Especificar la ruta relativa desde el directorio actual
ruta_csv_relativa = os.path.join('..', 'data', '01_raw','spotify.csv')

# Cargar el archivo CSV
spotify = pd.read_csv(ruta_csv_relativa)

# Mostrar las primeras filas del DataFrame
spotify.head(10)
```

Out[2]:

	Unnamed: 0	track_id	artists	album_name	track_name	popularity	duration_ms	explicit	danceability	energy	...	loudness	mode	speechiness	acousticness	instrumentalness	liveness	valence	tempo	time_signature
0	0	5SuOikwiRyPMVoIQDJUgSV	Gen Hoshino	Comedy	Comedy	73	230666	False	0.676	0.4610	...	-6.746	0	0.1430	0.0322	0.000001	0.3580	0.7150	87.917	4
1	1	4qPNDBW1i3p13qLCt0Ki3A	Ben Woodward	Ghost (Acoustic)	Ghost - Acoustic	55	149610	False	0.420	0.1660	...	-17.235	1	0.0763	0.9240	0.000006	0.1010	0.2670	77.489	4
2	2	1iJBSr7s7jYXzM8EGcbK5b	Ingrid Michaelson;ZAYN	To Begin Again	To Begin Again	57	210826	False	0.438	0.3590	...	-9.734	1	0.0557	0.2100	0.000000	0.1170	0.1200	76.332	4
3	3	6lfxq3CG4xtTiEg7opyCyx	Kina Grannis	Crazy Rich Asians (Original Motion Picture Sou...	Can't Help Falling In Love	71	201933	False	0.266	0.0596	...	-18.515	1	0.0363	0.9050	0.000071	0.1320	0.1430	181.740	3
4	4	5vjLSffimiIP26QG5WcN2K	Chord Overstreet	Hold On	Hold On	82	198853	False	0.618	0.4430	...	-9.681	1	0.0526	0.4690	0.000000	0.0829	0.1670	119.949	4
5	5	01MVOl9KtVTNfFiBU9I7dc	Tyrone Wells	Days I Will Remember	Days I Will Remember	58	214240	False	0.688	0.4810	...	-8.807	1	0.1050	0.2890	0.000000	0.1890	0.6660	98.017	4
6	6	6Vc5wAMmXdKIAM7WUoEb7N	A Great Big World;Christina Aguilera	Is There Anybody Out There?	Say Something	74	229400	False	0.407	0.1470	...	-8.822	1	0.0355	0.8570	0.000003	0.0913	0.0765	141.284	3
7	7	1EzrEOXmMH3G43AXT1y7pA	Jason Mraz	We Sing. We Dance. We Steal Things.	I'm Yours	80	242946	False	0.703	0.4440	...	-9.331	1	0.0417	0.5590	0.000000	0.0973	0.7120	150.960	4
8	8	0IktbUcnAGrvD03AWnz3Q8	Jason Mraz;Colbie Caillat	We Sing. We Dance. We Steal Things.	Lucky	74	189613	False	0.625	0.4140	...	-8.700	1	0.0369	0.2940	0.000000	0.1510	0.6690	130.088	4
9	9	7k9GuJYLp2AzqokyEdwEw2	Ross Copperman	Hunger	Hunger	56	205594	False	0.442	0.6320	...	-6.770	1	0.0295	0.4260	0.004190	0.0735	0.1960	78.899	4

10 rows × 21 columns

Escalado de datos

Este escalado de variables es para poder trabajar con los modelos en un futuro

duration_ms Scaler

population Scaler

In [3]:
```python
from sklearn.preprocessing import StandardScaler

# Crear un objeto StandardScaler
scaler = MinMaxScaler()

# Seleccionar solo la columna de popularidad para escalar
spotify['popularity_scaled'] = scaler.fit_transform(spotify[['popularity']])

# Mostrar las primeras filas para verificar
spotify[['popularity', 'popularity_scaled']].head()
```

Out[3]:

	popularity	popularity_scaled
0	73	0.73
1	55	0.55
2	57	0.57
3	71	0.71
4	82	0.82

Group feature Scaler

In [4]:
```python
from sklearn.preprocessing import MinMaxScaler

# Seleccionar las características numéricas para escalar
features_to_scale = ['danceability', 'energy', 'loudness', 'speechiness',
                     'acousticness', 'instrumentalness', 'liveness',
                     'valence', 'tempo']

scaler = MinMaxScaler()
spotify[features_to_scale] = scaler.fit_transform(spotify[features_to_scale])

print('Caracteristicas escaladas: ', features_to_scale)
```

```
Caracteristicas escaladas:  ['danceability', 'energy', 'loudness', 'speechiness', 'acousticness', 'instrumentalness', 'liveness', 'valence', 'tempo']
```

Creación de nuevas característica

duration_ms a tiempo_ms_seconds

La duración_ms se calculo para que los valores de milisegundos se pasen a minutos y segundos

In [5]:
```python
# Convertir milisegundos a segundos
spotify['tiempo_ms_seconds'] = spotify['duration_ms'] / 1000

# Función para convertir segundos a formato de minutos y segundos
def segundos_a_formato(segundos):
    minutos = int(segundos // 60)
    segundos_restantes = int(segundos % 60)
    return f"{minutos} minuto{'s' if minutos != 1 else ''} con {segundos_restantes} segundo{'s' if segundos_restantes != 1 else ''}"

# Aplicar la función a la columna de segundos
spotify['duration_ms_scaled'] = spotify['tiempo_ms_seconds'].apply(segundos_a_formato)

# Mostrar los primeros 10 valores formateados
print(spotify['duration_ms_scaled'].head(10))
```

```
0    3 minutos con 50 segundos
1    2 minutos con 29 segundos
2    3 minutos con 30 segundos
3    3 minutos con 21 segundos
4    3 minutos con 18 segundos
5    3 minutos con 34 segundos
6    3 minutos con 49 segundos
7     4 minutos con 2 segundos
8     3 minutos con 9 segundos
9    3 minutos con 25 segundos
Name: duration_ms_scaled, dtype: object
```

tranck_genre a Label Encoding

Cambiar la etiqueta categórica de track_genre a un valor numérico.

In [6]:
```python
from sklearn.preprocessing import LabelEncoder

# Crear el codificador de etiquetas
le = LabelEncoder()

# Aplicar Label Encoding a la columna 'track_genre'
spotify['track_genre_encoded'] = le.fit_transform(spotify['track_genre'])

# Ver las primeras filas para verificar la codificación
print(spotify[['track_genre', 'track_genre_encoded']].head())
```

```
  track_genre  track_genre_encoded
0    acoustic                    0
1    acoustic                    0
2    acoustic                    0
3    acoustic                    0
4    acoustic                    0
```

Nueva variable "Intensity"

Al tener una buena correlación gracias a la matriz, decidimos optar por juntar la energy con la danceability

In [7]:
```python
# Crear una nueva columna de "intensidad"
spotify['intensity'] = spotify['energy'] * spotify['danceability']

spotify['intensity'].head(10)
```

Out[7]:
```
0    0.316382
1    0.070782
2    0.159637
3    0.016095
4    0.277943
5    0.335968
6    0.060740
7    0.316885
8    0.262690
9    0.283598
Name: intensity, dtype: float64
```

Eliminación de característica

Se elimino.

Unnamed : 0 - artitst - album_name - track_id - track_name - explicit - time_signature - mode - duration_ms - log_duration_ms

Correlation Matrix

In [8]:
```python
# Selección de Datos Numéricos
datosNumericos = spotify.select_dtypes(include=[np.number])

# Calcular la matriz de correlación
matriz_correlacion = datosNumericos.corr()

# Mostrar la matriz de correlación
plt.figure(figsize=(8, 6))
sns.heatmap(matriz_correlacion, annot=True, fmt=".2f", cmap="coolwarm", square=True, cbar_kws={'shrink': .8})
plt.title('Matriz de Correlación')
plt.show()
```

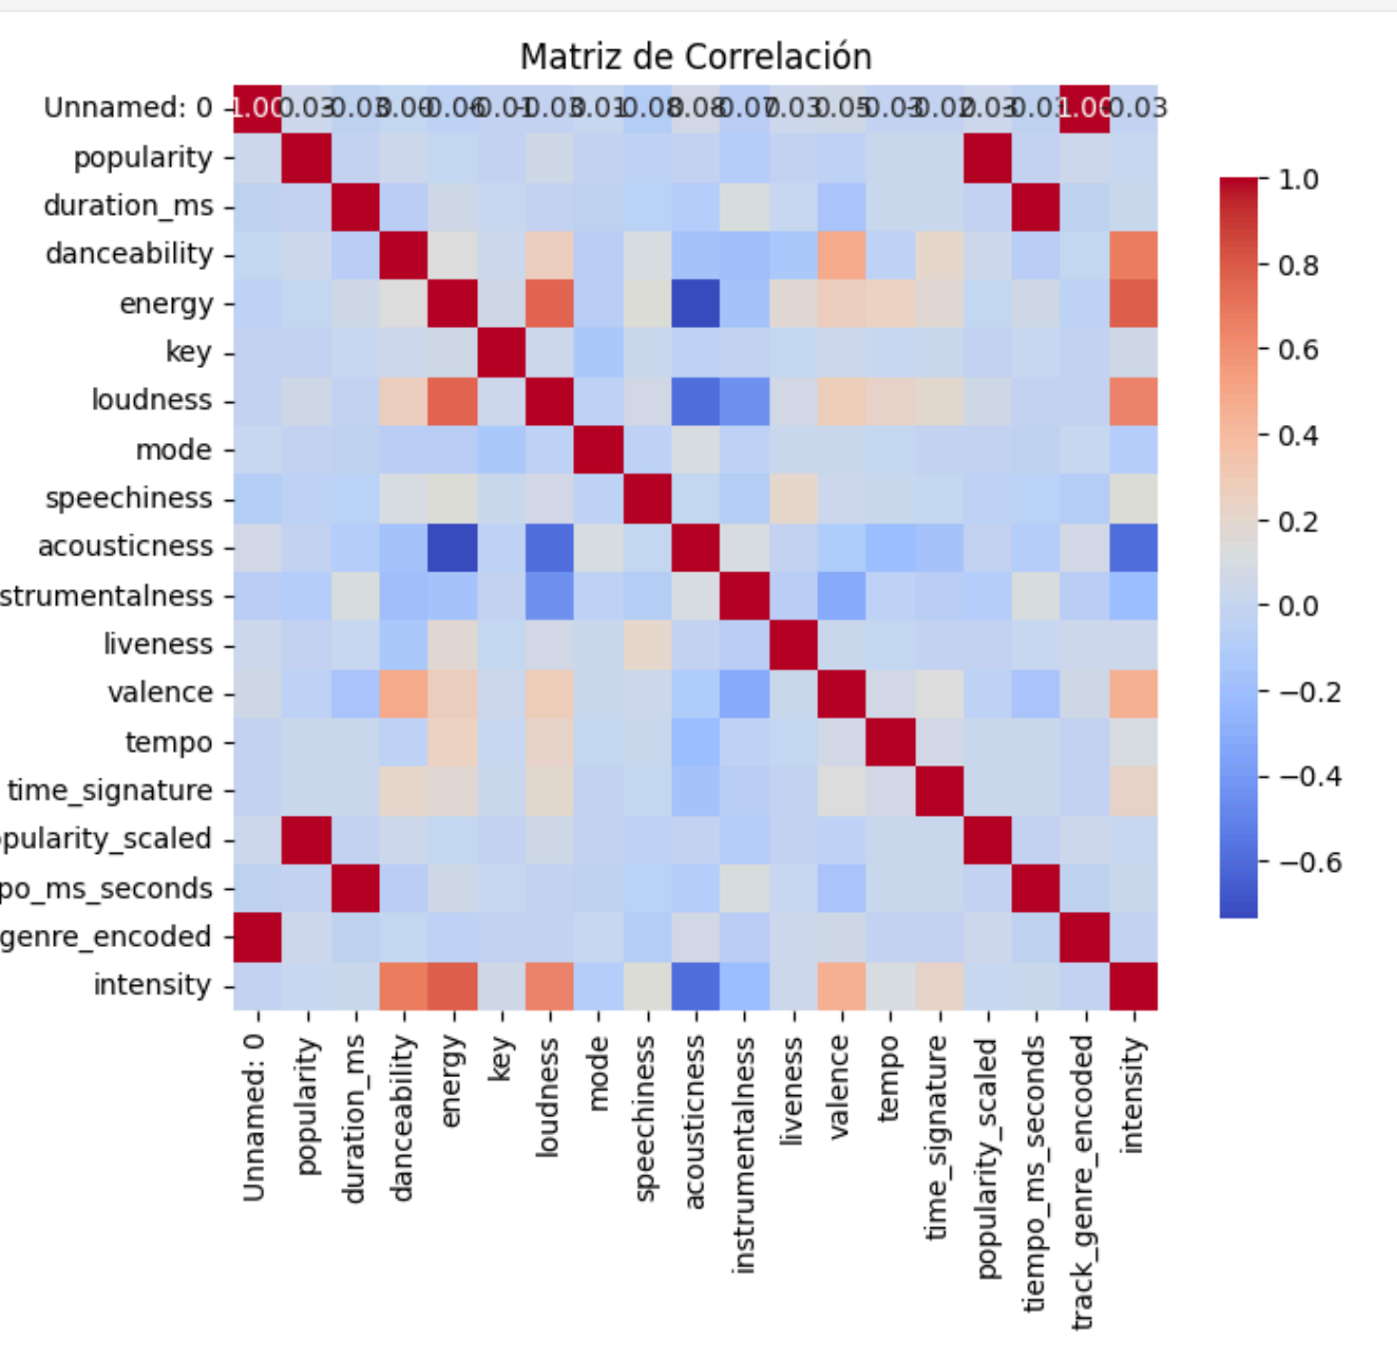

Exploración nuevo DataSet "spotify"

Información del DataSet

In [9]:
```python
spotify.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 114000 entries, 0 to 113999
Data columns (total 26 columns):
 #   Column               Non-Null Count   Dtype  
---  ------               --------------   -----  
 0   Unnamed: 0           114000 non-null  int64  
 1   track_id             114000 non-null  object 
 2   artists              113999 non-null  object 
 3   album_name           113999 non-null  object 
 4   track_name           113999 non-null  object 
 5   popularity           114000 non-null  int64  
 6   duration_ms          114000 non-null  int64  
 7   explicit             114000 non-null  bool   
 8   danceability         114000 non-null  float64
 9   energy               114000 non-null  float64
 10  key                  114000 non-null  int64  
 11  loudness             114000 non-null  float64
 12  mode                 114000 non-null  int64  
 13  speechiness          114000 non-null  float64
 14  acousticness         114000 non-null  float64
 15  instrumentalness     114000 non-null  float64
 16  liveness             114000 non-null  float64
 17  valence              114000 non-null  float64
 18  tempo                114000 non-null  float64
 19  time_signature       114000 non-null  int64  
 20  track_genre          114000 non-null  object 
 21  popularity_scaled    114000 non-null  float64
 22  tiempo_ms_seconds    114000 non-null  float64
 23  duration_ms_scaled   114000 non-null  object 
 24  track_genre_encoded  114000 non-null  int64  
 25  intensity            114000 non-null  float64
dtypes: bool(1), float64(12), int64(7), object(6)
memory usage: 21.9+ MB
```

Cantidad total de datos

In [10]:
```python
spotify.dtypes.value_counts()
```

Out[10]:
```
float64    12
int64       7
object      6
bool        1
Name: count, dtype: int64
```

Futuro

El objetivo de este proyecto es desarrrollar un sistema de recomendación de música. Específicamente usando K-Means y K-Vecinos más cercanos (K-NN). Hemos utilizado el procedimiento previo para preparar el conjunto de datos.

- Escalado de variables: La mayoría de las variables numéricas han sido escaladas. Para asegurar que todas las características sean similares.

- Eliminación de variables categóricas: Las variables categóricas se han eliminado o transformado con el método de Label Encoding, para evitar problemas con los algoritmos que no puedan procesar ese tipo de dato.

El sistema de recomendación funcionará agrupando canciones similares (K-Means) o sugiriendo canciones basadas a las características (K-NN). De esta forma se busca que el sistema pueda recomendar canciones que se alineen con el gusto del usuario.

Cabe recalcar que el método para lograr el objetivo puede cambiar al avanzar con el desarrollo y evaluación de los modelos. Nuestra intención es buscar el mejor modelo para nuestro Recomendador.

In [11]:
```python
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans

# Supongamos que 'spotify' es tu DataFrame original

# Lista para almacenar la inercia (Suma de los errores al cuadrado)
inertia = []

# Probar diferentes valores de k (por ejemplo, de 1 a 10)
k_values = range(1, 11)
for k in k_values:
    kmeans = KMeans(n_clusters=k, random_state=42)
    kmeans.fit(spotify[['popularity', 'danceability', 'energy', 'loudness',
                         'speechiness', 'acousticness', 'instrumentalness', 'liveness',
                         'valence', 'tempo', 'duration_ms']])  # Seleccionar las columnas necesarias
    inertia.append(kmeans.inertia_)

# Graficar los resultados
plt.plot(k_values, inertia, 'bx-')
plt.xlabel('Número de clusters (k)')
plt.ylabel('Inercia')
plt.title('Método del codo para seleccionar el valor óptimo de k')
plt.show()
```

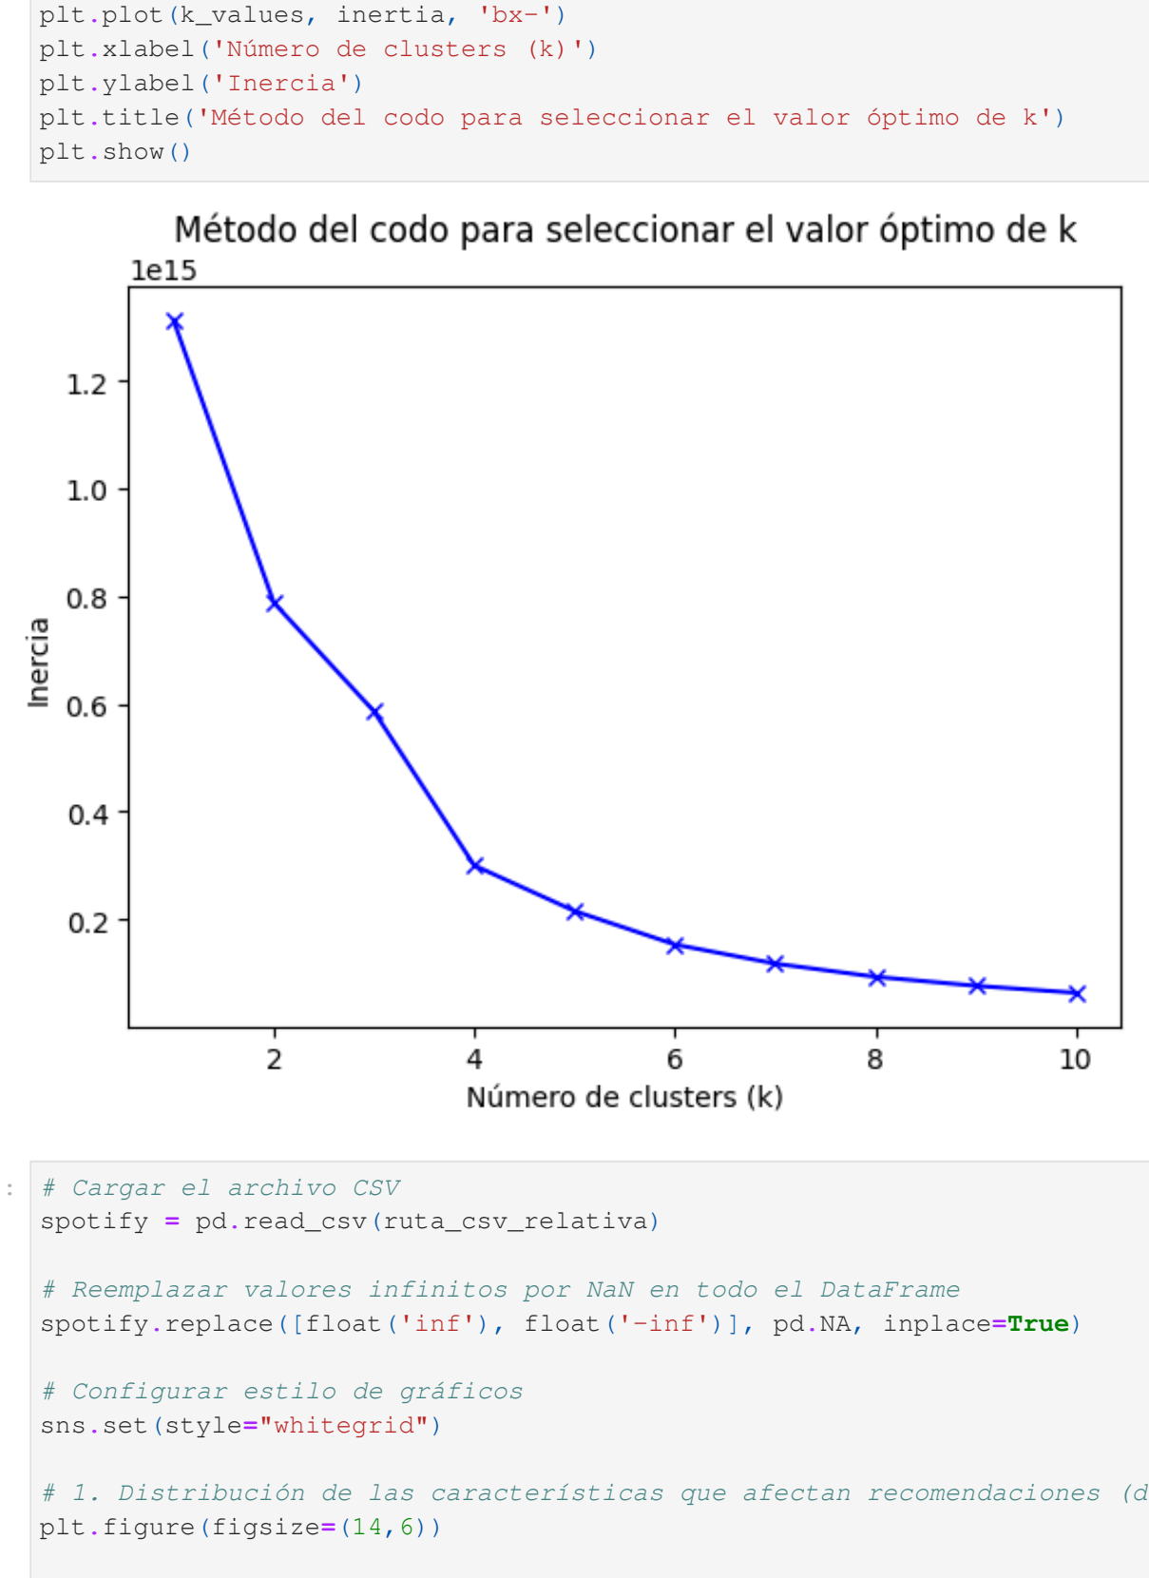

In [12]:
```python
# Cargar el archivo CSV
spotify = pd.read_csv(ruta_csv_relativa)

# Reemplazar valores infinitos por NaN en todo el DataFrame
spotify.replace([float('inf'), float('-inf')], pd.NA, inplace=True)

# Configurar estilo de gráficos
sns.set(style="whitegrid")

# 1. Distribución de las características que afectan recomendaciones (danceability, energy, valence)
plt.figure(figsize=(14,6))

# Subplots para cada característica
for i, feature in enumerate(['danceability', 'energy', 'valence'], 1):
    plt.subplot(1, 3, i)
    sns.histplot(spotify[feature].dropna(), bins=30, kde=True, color='teal')
    plt.title(f'Distribución de {feature.capitalize()}')
    plt.xlabel(feature.capitalize())
    plt.ylabel('Frecuencia')

plt.tight_layout()
plt.show()

# 2. Relación entre Género y las características para recomendaciones
plt.figure(figsize=(14,8))
top_genres = spotify['track_genre'].value_counts().nlargest(10)  # Top 10 géneros
sns.boxplot(x='track_genre', y='danceability', data=spotify[spotify['track_genre'].isin(top_genres.index)].dropna(), palette='coolwarm')
plt.title('Danceability por Género de Canción')
plt.xticks(rotation=90)
plt.show()

# 3. Conteo de canciones explícitas
plt.figure(figsize=(6,6))
sns.countplot(x='explicit', data=spotify, palette='Set2')
plt.title('Canciones Explícitas vs No Explícitas')
plt.xlabel('Explícito')
plt.ylabel('Conteo')
plt.show()
```

```
C:\Users\Cracklitrox\Desktop\Spotify-Recomendation-Machine-Learning\.venv\Lib\site-packages\seaborn\_oldcore.py:1119: FutureWarning: use_inf_as_na option is deprecated and will be removed in a future versio
n. Convert inf values to NaN before operating instead.
  with pd.option_context('mode.use_inf_as_na', True):
C:\Users\Cracklitrox\Desktop\Spotify-Recomendation-Machine-Learning\.venv\Lib\site-packages\seaborn\_oldcore.py:1119: FutureWarning: use_inf_as_na option is deprecated and will be removed in a future versio
n. Convert inf values to NaN before operating instead.
  with pd.option_context('mode.use_inf_as_na', True):
C:\Users\Cracklitrox\Desktop\Spotify-Recomendation-Machine-Learning\.venv\Lib\site-packages\seaborn\_oldcore.py:1119: FutureWarning: use_inf_as_na option is deprecated and will be removed in a future versio
n. Convert inf values to NaN before operating instead.
  with pd.option_context('mode.use_inf_as_na', True):
```

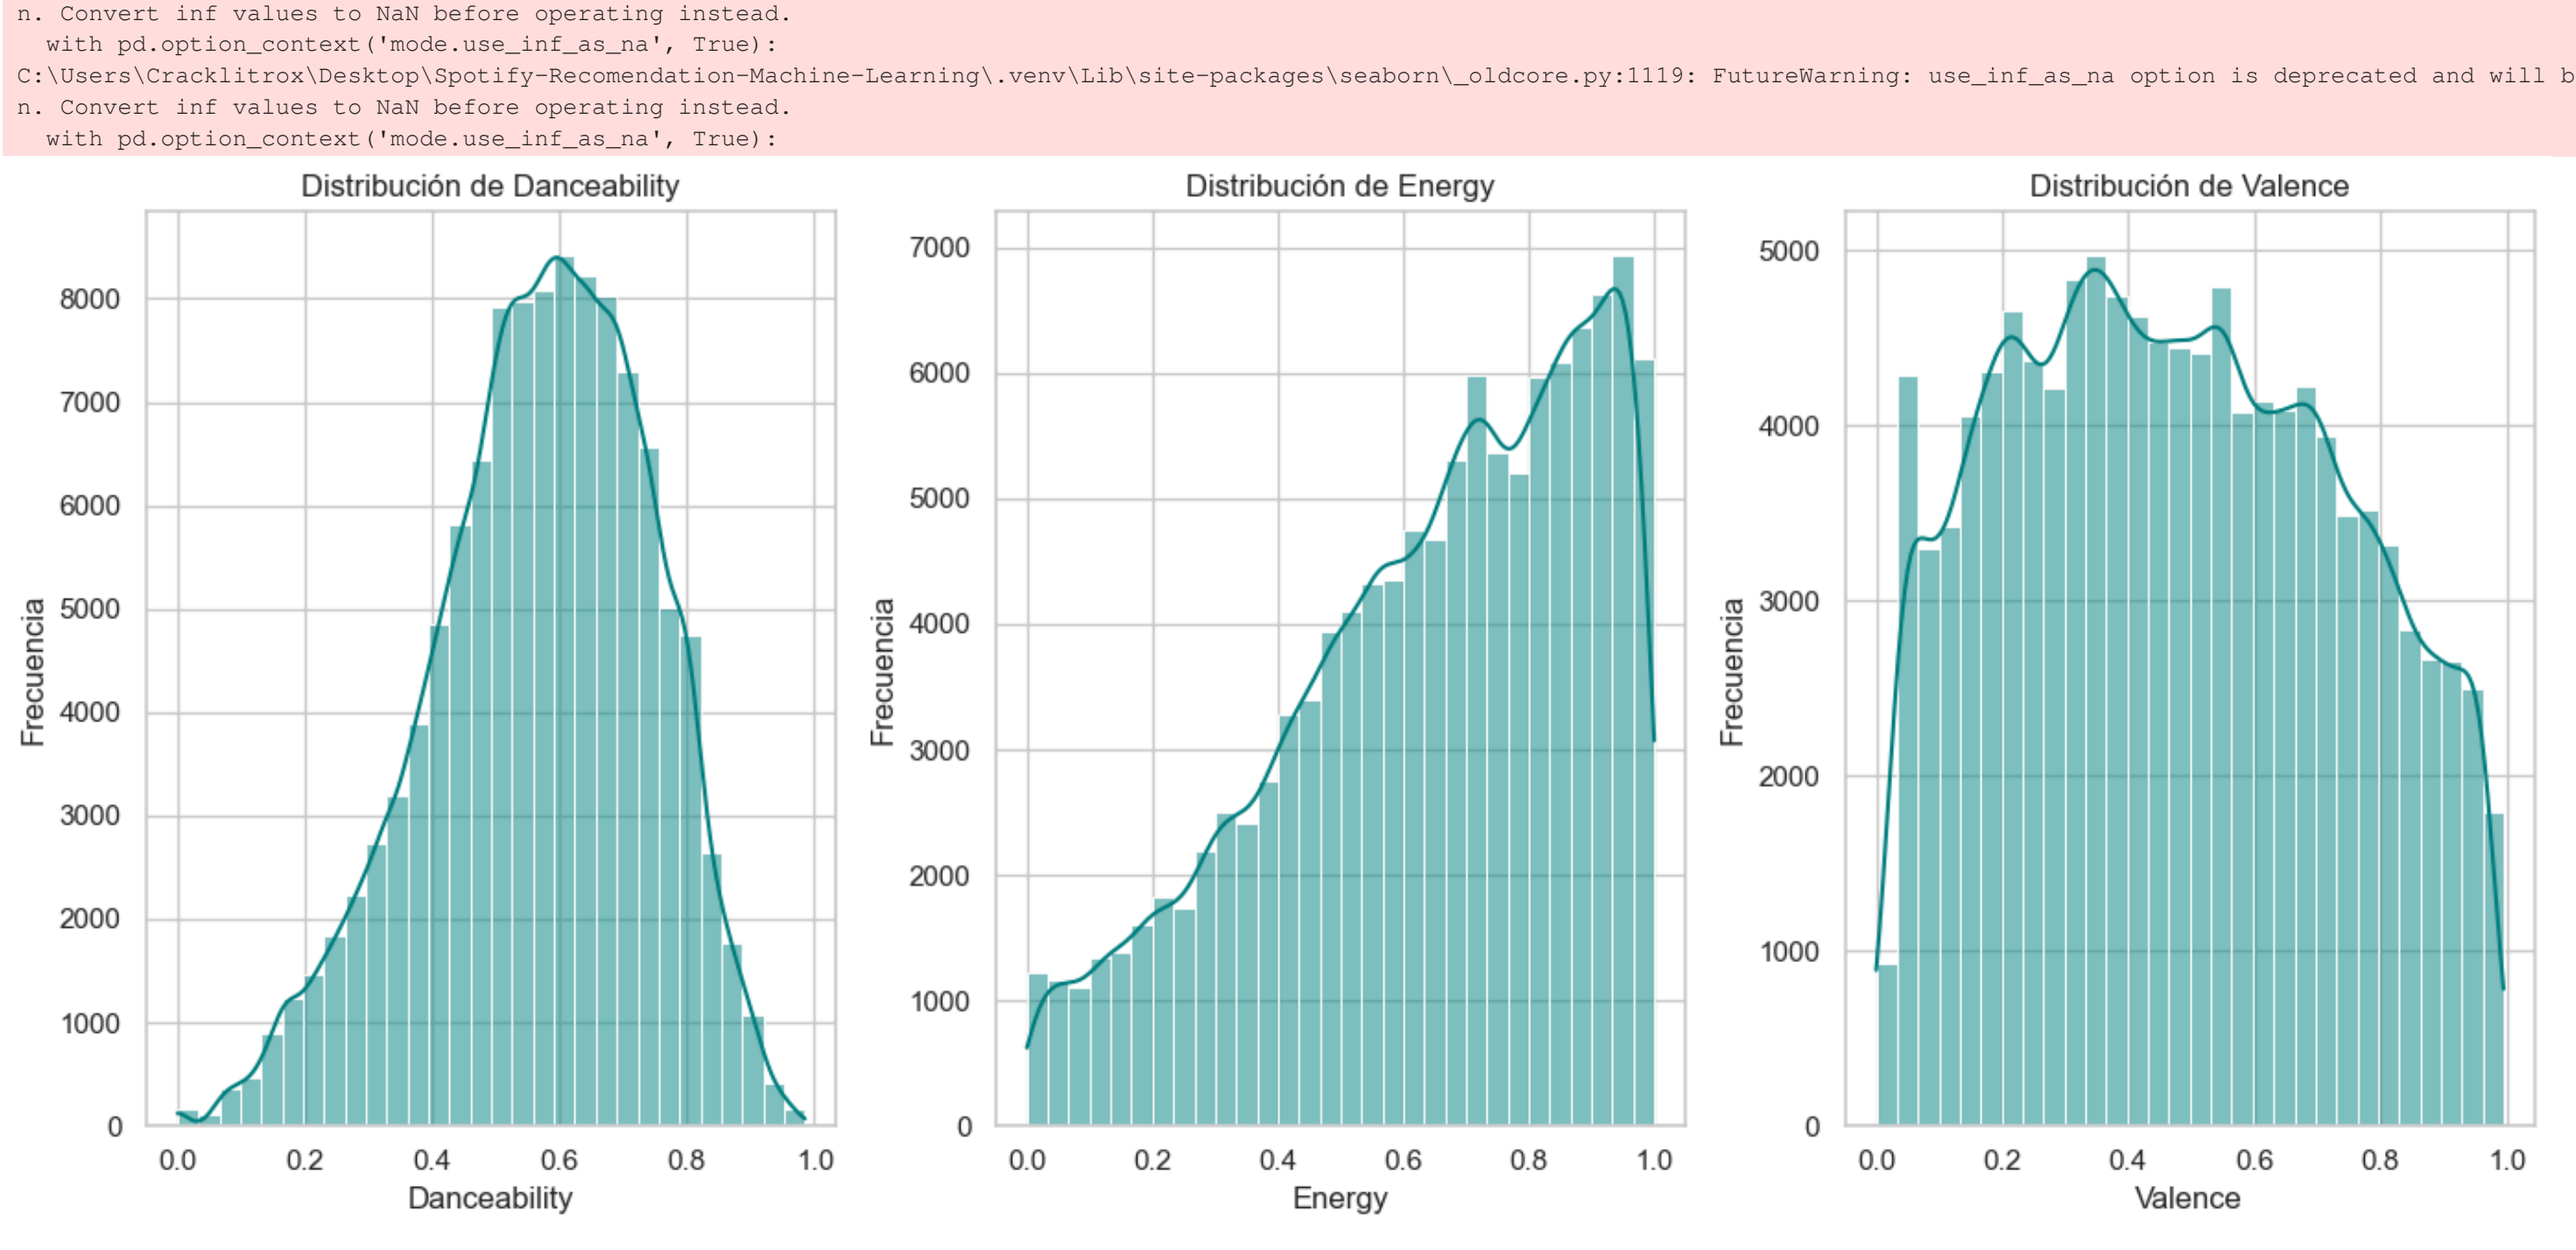

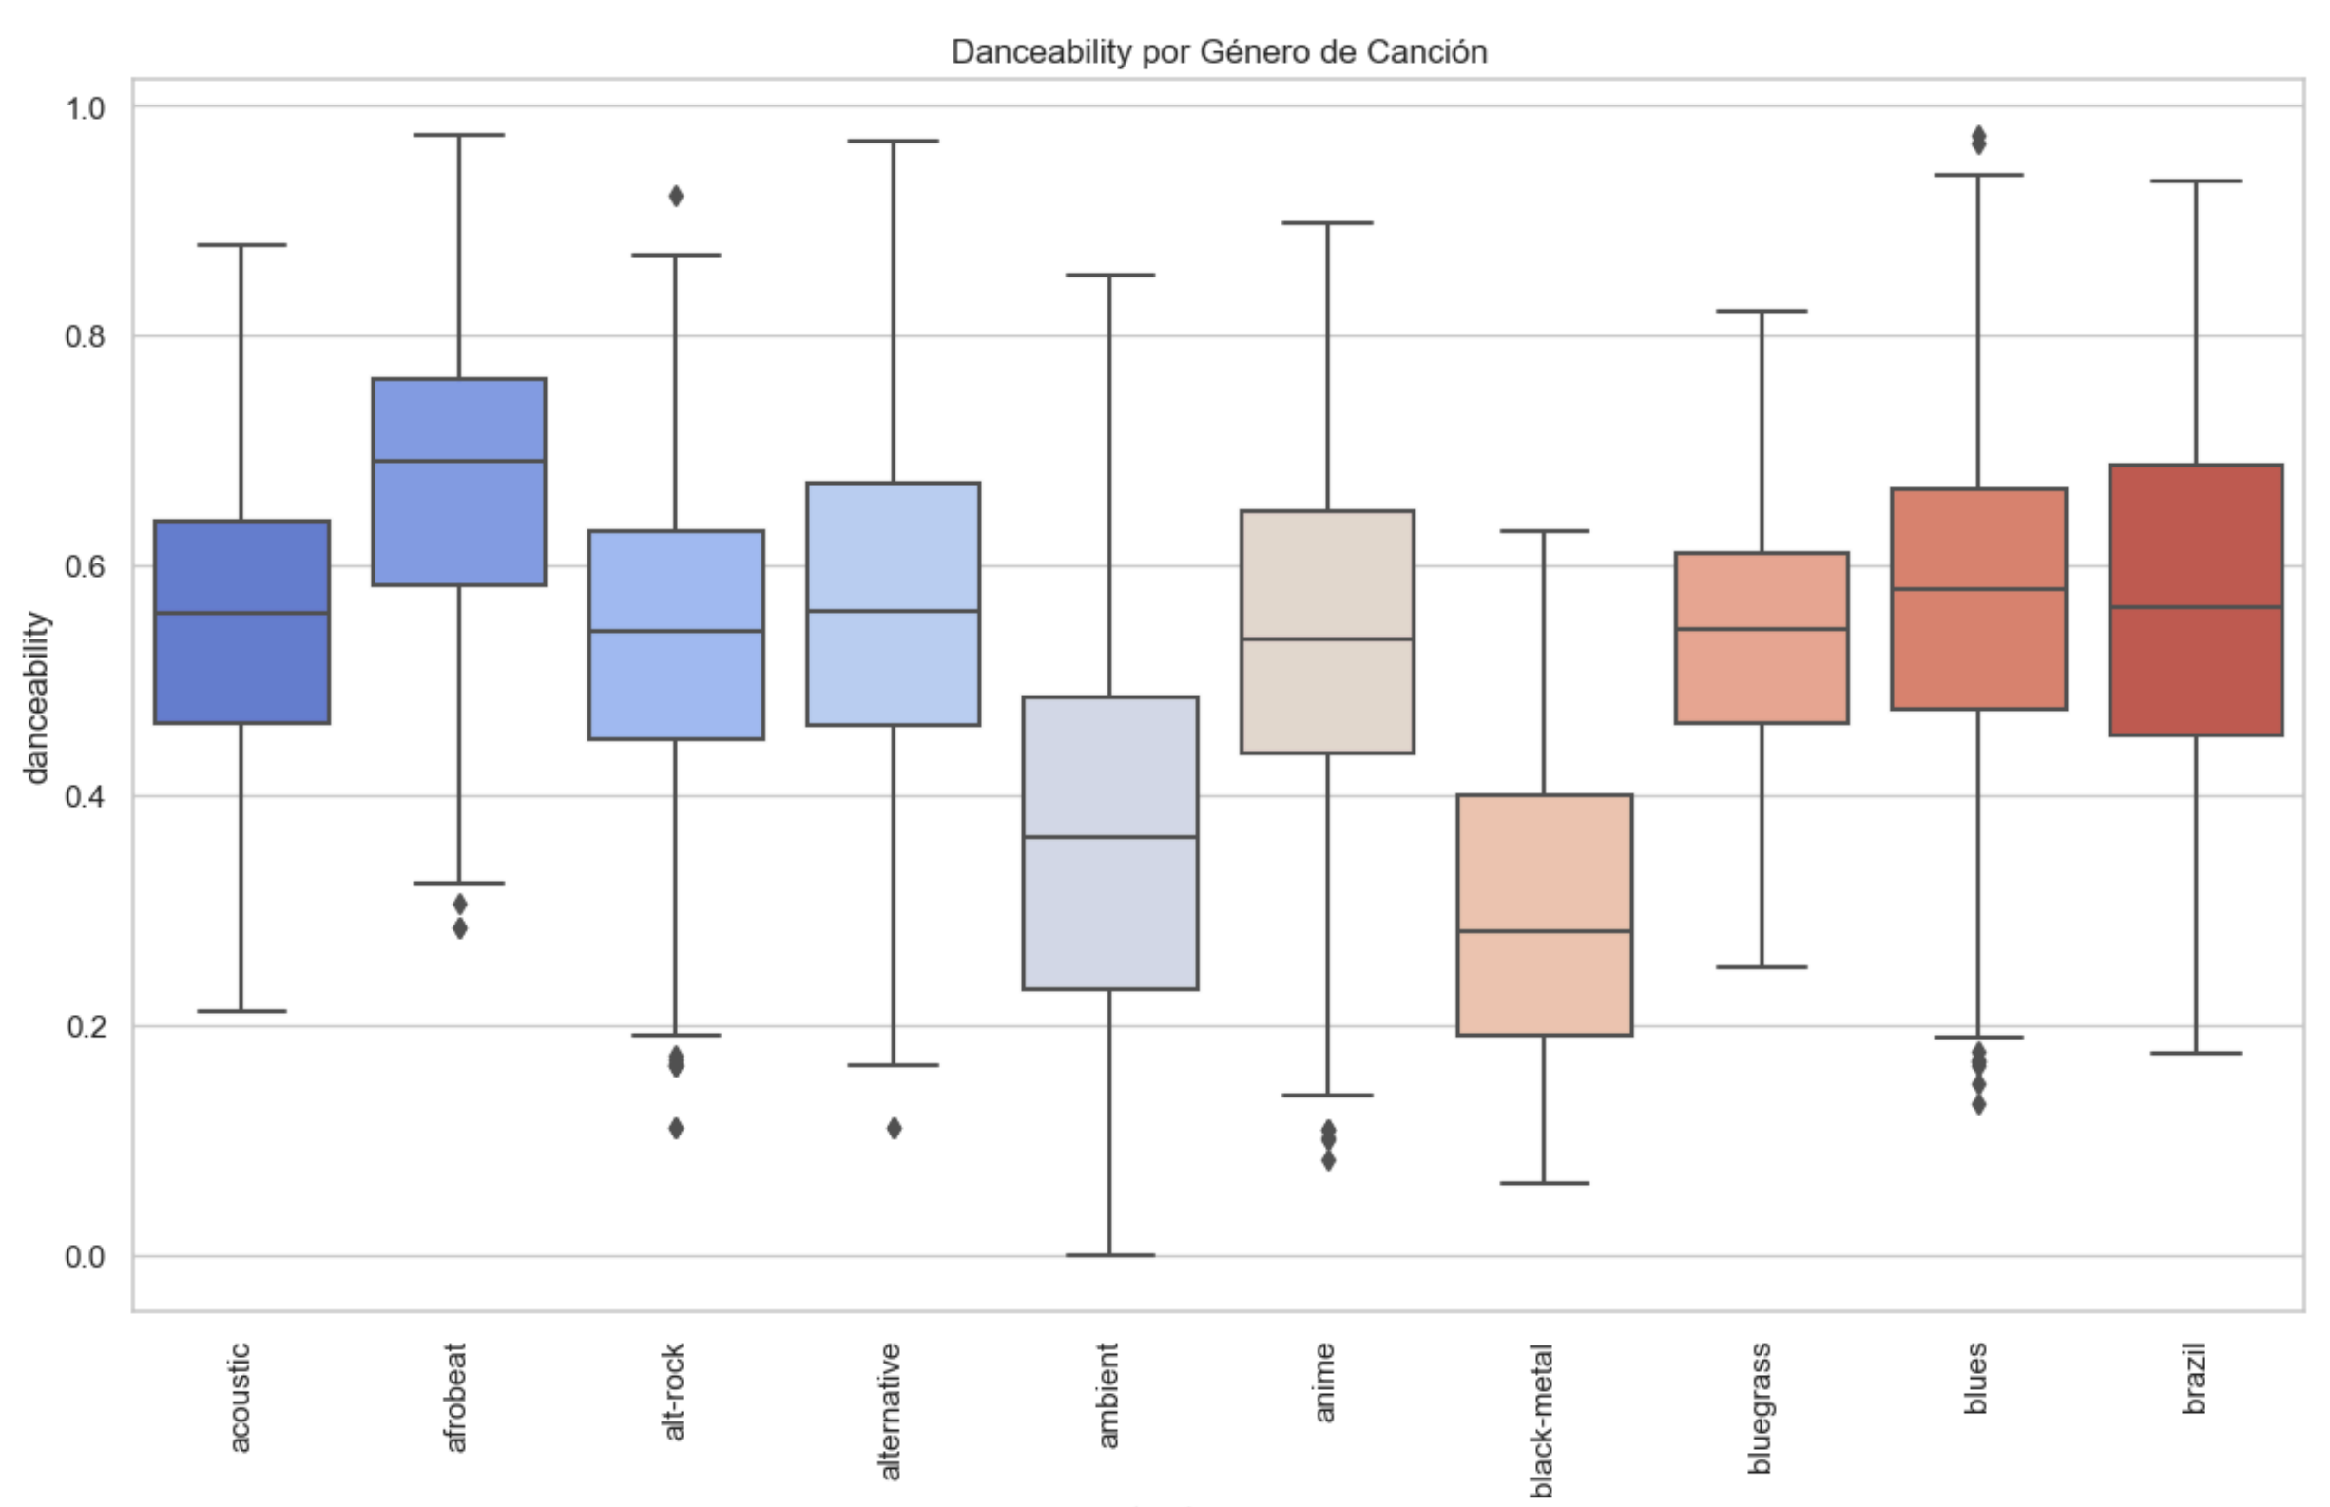

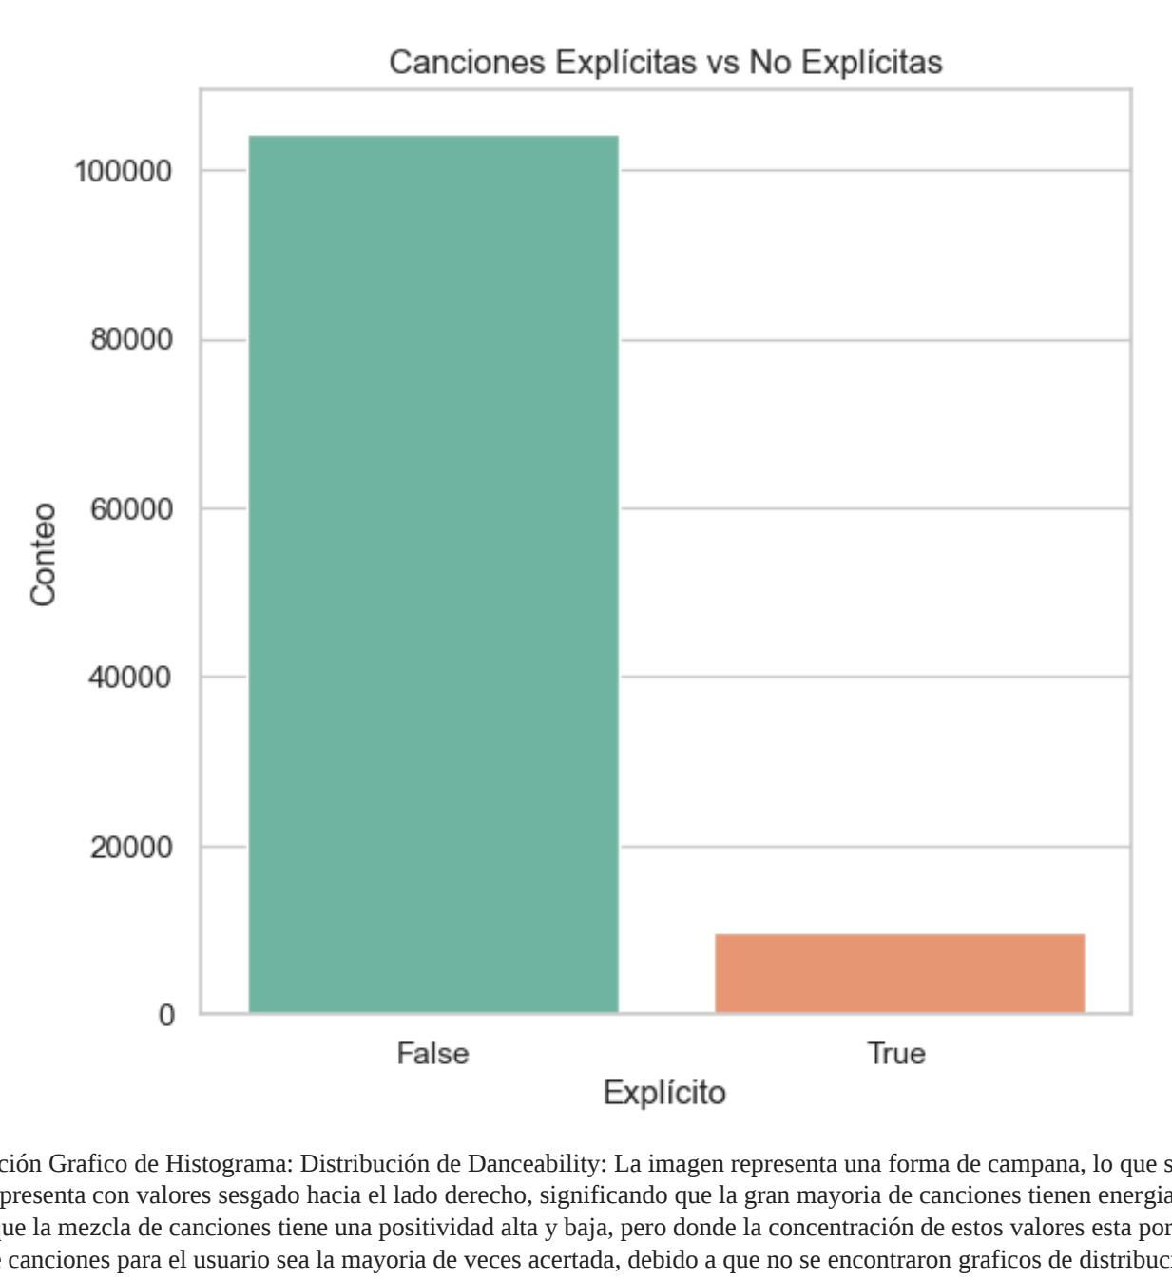

Explicación Grafico de Histograma: Distribución de Danceability: La imagen representa una forma de campana, lo que significa que la mayoria de las canciones son bailables, sugiriendo que no afecta en gran medida este campo al recomendar canciones para el usuario que varia en gustos. Distribución de Energy: El grafico lo representa con valores sesgado hacia el lado derecho, significando que la gran mayoria de canciones tienen energia alta, es decir, que si un usuario opta por 'x' cancion, lo más probable es que la recomendación deba ser con niveles de Energy similares o iguales. Distribución de Valence: Una distribución uniforme, sugiriendo que la mezcla de canciones tiene una positividad alta y baja, pero donde la concentración de estos valores esta por la mitad del grafico. En resumen, el sentimiento o ambiente de las canciones esta relacionada en su mayoria por estos tres campos donde la variabilidad de los valores es casi nula, permitiendo que la busqueda de canciones para el usuario sea la mayoria de veces acertada, debido a que no se encontraron graficos de distribución con valores atipicos, si no que más bien, sus resultados son por lo generales cercanos y por consiguiente, acertados. Boxplot de Danceability por genero de cancion: El siguiente grafico muestra las relaciones de los generos de musica, donde se destaca que cada caja muestra la distribución del campo Danceability por genero de musica. Como se puede observar, generos como 'Alt-Rock' y 'Afrobeat' tienen canciones más bailables que generos como 'ambiente' o 'blues'. Esto nos sirve para recomendar generos de musica para el usuario basadas en sus canciones favoritas, de esta forma tenemos los generos mas cercanos y los mas alejados. Cantidad de canciones con letras explicitas y no explicitas: Como se puede observar, la cantidad de canciones no explicitas ronda los más de 100.000 canciones, a comparaciónes de las canciones que si contienen letra explicita, donde el valor ronda los 8.000 a 10.000 canciones. Esta opción es crucial para la recomendaciones de canciones, puesto que si el usuario opta por canciones que tengan letras explicitas, en numero de recomendaciones baja drasticamente que eligiendo canciones sin letra explicitas, aun que tambien

de la opción de que pueda elegir en ambas opciones. Esto va acompañado con la pregunta de negocio 3, que nos muestra el numero exacto de canciones con letras explicitas por genero de musica. Conclución: Los graficos mostrados nos entregan una resolución amplia donde se abarcan temas de ambiente o sentimientos que entregan las canciones, similitud entre los generos de musica en base a su bailabilidad y cantidad de canciones con y sin letras explicitas. Esto nos permitira definir de una manera mas exacta las recomendaciones que entreguemos al usuario en base a sus gustos.